

WYKORZYSTANIE METAHEURYSTYCZNYCH METOD OPTYMALIZACYJNYCH W PROBLEMIE TRANSPORTOWYM TSP

Kacper Hajduk - 149010, grupa: pon, 15.12

Wstęp

Przedmiotem raportu jest implementacja 4 algorytmów optymalizacyjnych, w tym prymitywnego, zachłannego algorytmu najbliższego sąsiada służącego za baseline dla oceny reszty modeli, oraz 3 metaheurystyk: listy tabu, wyżarzania symulowanego oraz algorytmu genetycznego. Na każdą z metod nałożone zostało ograniczenie czasowe, zaimplementowane poprzez odgórną regułę zatrzymania modelu. Limit ten służy porównaniu metod względem siebie. Każda z metaheurystyk znalazła inne rozwiązanie "optymalne" (w sensie pojedynczej sesji obliczeń dla algorytmu), każdą z technik cechowała również odmienna trajektoria zmian wartości funkcji celu. Solvery napisane zostały w języku Python.


Opis problemu

W projekcie rozważany jest klasyczny problem traveling salesman (TSP) - tzn. naszym zadaniem jest znalezienie trasy pozwalającej trafić do każdego z interesujących nas miejsc dokładnie raz, a zarazem będącej możliwie najkrótszą. Choć rozważany problem jest wykorzystywany często jako klasyczny przykład służący przedstawieniu technik optymalizacyjnych, reprezentuje on jednocześnie bardzo częsty i powszechnie spotykany w praktyce biznesowej, zarządczej czy naukowej problem optymalizacyjny, przekładający się na realne koszty i konsekwencje dla działających, szczególnie w obszarze logistyki, przedsiębiorstw.

W projekcie opisujemy próby znalezienia optymalnego rozwiązania dla 50 miejscowości położonych w województwie Podlaskim. Każda trasa musi zaczynać się z tego samego punktu startowego (Białystok) oraz się w nim kończyć. Daje to łącznie 49! (w przybliżeniu 6.08×10^{62}) wariantów tras, co wyklucza prostą enumerację i zmusza nas do wykorzystania bardziej wysublimowanych technik.

Dane

Dane reprezentujemy abstrakcyjnie w postaci grafu, a na poziomie struktur danych - macierzy "przejeźd". Dla każdej z miejscowości znaleziony został najbliższy względem jej współrzędnych węzeł w danych OpenStreetMap, oraz obliczona została najkrótsza droga do każdej z pozostałych miejscowości (za pomocą algorytmu Dijkstry - ten konkretny problem optymalizacyjny nie jest przedmiotem naszego projektu). Trasy końcowe zostały zwizualizowane z pomocą biblioteki folium, która pozwala na interaktywną prezentację ostatecznych rozwiązań poprzez wizualizację tras na mapie i wgląd w rozwiązania wygenerowane przez każdą z technik.



Wykres 1. Wygenerowana sieć tras

Algorytmy

Nearest Neighbor (Najbliższy Sąsiad)

Algorytm zachłanny, który zaczynając od Białegostoku, w każdym kroku wybiera zawsze najbliższe nieodwiedzone jeszcze miasto. Wynik otrzymujemy bardzo szybko, ale jest on najslabiej zoptymalizowany względem reszty wykorzystanych metod.

Lista Tabu

Algorytm wykorzystuje listę tabu o pojemności 25 wariantów, która przechowuje ostatnio wykonane ruchy kierując się regułą FIFO, co zapobiega zapętleniom i pozwala algorytmowi wyjść z maksimów lokalnych. Operatorem przeszukującym przestrzeń potencjalnych tras jest 2-opt swap.

Algorytm Genetyczny

Rozmiar populacji ustalono na 150 osobników. Model korzysta z selekcji turniejowej (wybór najlepszego z 3 losowych wariantów), krzyżowania porządkowego typu Order Crossover.

Wyżarzanie Symulowane

Metoda inspirowana algorytmem Metropolis-Hastingsa. Temperatura początkowa (T) wynosi 50000.0 i systematycznie maleje z każdą kolejną iteracją algorytmu, naprowadzając z czasem metodę w kierunku zachłanności i lokalnego przeszukiwania.

Wyniki



Wszystkie cztery metody dysponowały identycznym limitem czasowym dla przeszukiwania przestrzeni rozwiązań, wynoszącym 5 sekund (dla 50 miejscowości, ten konkretny limit pokazuje już różnicę w działaniu algorytmów). Zestawienie uzyskanych odległości końcowych przedstawia poniższa tabela:

Algorytm / Metoda	Dystans końcowy (km)	Charakterystyka zbieżności
Nearest Neighbor	1641.73 km	Zbiega natychmiast, metoda deterministyczna, brak wpływu limitu czasowego.

Algorytm / Metoda	Dystans końcowy (km)	Charakterystyka zbieżności
Tabu Search	1203.55 km	Najlepszy wynik (minimum). Skokowe i gwałtowne poprawy ścieżki, dobrze radzi sobie z lokalnymi minimami.
Algorytm Genetyczny	1536.25 km	Najslabsza zbieżność wśród wykorzystanych metaheurystyk. Metoda zasobochołonna.
Wyżarzanie Symulowane	1216.87 km	Bardzo płynna zbieżność, wynik zbliżony do Tabu Search, choć minimalnie gorszy.



Analizując historię zbieżności poszczególnych metod, można zauważyć odmienną dynamikę dochodzenia do ostatecznych wyników:

- **Nearest Neighbor:** Jako technika zachłanna, tworzy rozwiązanie najszybciej, ale względem reszty metod, jest ono wysoce suboptymalne.
- **Tabu Search:** Algorytm w ciągu 5 sekund schodzi najniżej, osiągając dystans 1203.55 km. Na wykresie zbieżności widać, że TS potrafi gwałtownie poprawić swoje rozwiązanie i sukcesywnie "spłaszcza" funkcję celu z każdym skokiem, dobrze radząc sobie z lokalnymi minimami.




Wykresy 2) Zmiany rozwiązań wraz z czasem treningu w algorytmie listy tabu oraz 3) finalna trasa

- **Algorytm Genetyczny:** Pokazuje najslabszą zbieżność spośród użytych metaheurystyk, osiągając zaledwie 1536.25 km. Trajektoria wartości funkcji celu dla kolejnych rozwiązań w zadanym limicie czasowym sugeruje, że dla 50 miast złożoność operatorów krzyżowania i ewolucji populacji staje się "wąskim gardłem", przez co GA generuje stosunkowo małą liczbę iteracji/generacji na tle innych modeli, co spowalnia jego zbieżność do optimum.



Wykresy 4. *Zmiany rozwiązań w algorytmie genetycznym oraz finalna trasa*

- Wyżarzanie Symulowane:** Pokazuje bardzo płynną i szybką zbieżność, kończąc obliczenia z wynikiem 1216.87 km. Wykres ilustruje, że w skutek znalezienia już stosunkowo dobrego rozwiązania (lokalnego minimum) i stygnięcia, ograniczona eksploracja nie pozwala “wymknąć się” z minimum lokalnego i osiągnąć wynik równy wynikowi listy tabu.




Rysunki 6. i 7. Rozwiązanie *względem czaseu treningu wyżarzania symulowanego oraz finalna trasa*

Wnioski

Analiza przeprowadzonych symulacji wskazuje na dużą dysproporcję w efektywności metaheurystyk ograniczonych kryterium czasowym, pokazując różnice w dostosowaniu do problemu oraz zasobożłonność różnych algorytmów.

Najlepiej poradził sobie algorytm **tabu search (1203.55 km)**, osiągając wynik zbliżony do **wyżarzania symulowanego (1216.87 km)**. Co ciekawe oba algorytmy tworzą trasy o bardzo podobnym kształcie - wypukłej okężnicy pozbawionej przejazdów między "wąskimi gardłami", tj. punktów położonych tak blisko siebie, że w tradycyjnym podejściu opartym o doborze kolejnych lokalnie najlepszych kroków połączenie między nimi zostałoby prawie na pewno stworzone.



Wykres 8. Z prawej trasa tabu search, z lewej nałożone na siebie tabu search oraz najbliższy sąsiad. Zwracamy uwagę na charakterystyczne przecięcia trasy tabu search przez "greedy skróty" wygenerowane w algorytmie czysto zachłannym

Zdecydowanie najgorzej wypadł Algorytm Genetyczny (1536.25 km), który zaledwie nieznacznie pokonał trywialny model Nearest Neighbor (1641.73 km). Wyżarzanie symulowane i Tabu Search, opierając się na bardzo szybkiej operacji zamiany krawędzi (2-opt) i prostszym mechanizmie ewaluacyjnym, są w stanie w tym samym czasie przeanalizować nieporównywalnie więcej sąsiedztw. Koszt obliczeniowy związany z utrzymaniem 150-elementowej populacji i skomplikowanym łączeniem się w pary sprawia, że w 5 sekund algorytm nie ewoluuje na tyle głęboko, by znaleźć optymalną ścieżkę, porównywalną z resztą metaheurystyk. Zastosowanie baseline'u w postaci algorytmu najbliższego sąsiada pokazało, że dobrze "nastrojona" (względem operatorów i hiperparametrów) metaheurystyka, szczególnie dostosowana do konkretnego problemu optymalizacyjnego, jest w stanie niewielkim kosztem dać znacznie lepsze efekty, niż proste podejście zachłanne.

Repozytorium z kodem:

<https://github.com/konterfektcesarza/NMO>